Sửa bài 7.19 - Thống Kê Nhiều Chiều - Nhóm 6

Nguyễn Đức Vũ Duy - 18110004

Đinh Anh Huy - 18110103

```
1 import itertools
2 import time
3 import numpy as np
4 import pandas as pd
5 import seaborn as sns
6 import statsmodels.api as sm
7 import matplotlib.pyplot as plt
8 from sklearn import linear_model
9 from scipy.stats import f
10 from sklearn.metrics import mean_squared_error
```

```
/usr/local/lib/python3.7/dist-packages/statsmodels/tools/_testing.py:19: FutureWarning: pandas.util.testing i
  import pandas.util.testing as tm
```

Một ứng dụng vệ tinh kích thích bởi sự phát triển của một loại pin silver_zino. Bảng 7.5 bao gồm các dữ liệu thất bại được thu thập để nghiên cứu tính hiệu quả của cục pin trong chu kì sống của nó. Sử dụng bộ dữ liệu này để:

a) Tìm ước lượng hồi quy tuyến tính của ln(Y) trong bộ tập con các biến dự đoán phù hợp

```
1 path='/content/T7-5.DAT.txt'
2 df=pd.DataFrame(np.loadtxt(path))
3 df.head()
```

	0	1	2	3	4	5
0	0.375	3.13	60.0	40.0	2.00	101.0
1	1.000	3.13	76.8	30.0	1.99	141.0
2	1.000	3.13	60.0	20.0	2.00	96.0
3	1.000	3.13	60.0	20.0	1.98	125.0
4	1.625	3.13	43.2	10.0	2.01	43.0

```
1 df.iloc[:,5]=np.log(df.iloc[:,5])
2 df.head()
```

	0	1	2	3	4	5
0	0.375	3.13	60.0	40.0	2.00	4.615121
1	1.000	3.13	76.8	30.0	1.99	4.948760
2	1.000	3.13	60.0	20.0	2.00	4.564348
3	1.000	3.13	60.0	20.0	1.98	4.828314
4	1.625	3.13	43.2	10.0	2.01	3.761200

```
1 def fit_linear_reg(X,Y):
2     #Fit linear regression model and return RSS and R squared values
3     model_k = linear_model.LinearRegression(fit_intercept = True)
4     model_k.fit(X,Y)
5     RSS = mean_squared_error(Y,model_k.predict(X)) * len(Y)
6     R_squared = model_k.score(X,Y)
7     return RSS, R_squared
```

```
1 #Initialization variables
2 Y = df.iloc[:,5]
3 X = df.iloc[:,:5]
4 k = 5
5
6 remaining_features = list(X.columns.values)
7 features = []
8 RSS_list, R_squared_list = [np.inf], [np.inf] #Due to 1 indexing of the loop...
```

```
features_list = dict()

for i in range(1,k+1):
    best_RSS = np.inf

    for combo in itertools.combinations(remaining_features,1):

            RSS = fit_linear_reg(X[list(combo) + features],Y)   #Store temp result

            if RSS[0] < best_RSS:
                best_RSS = RSS[0]
                best_R_squared = RSS[1]
                best_feature = combo[0]

    #Updating variables for next loop
    features.append(best_feature)
    remaining_features.remove(best_feature)

    #Saving values for plotting
    RSS_list.append(best_RSS)
    R_squared_list.append(best_R_squared)
    features_list[i] = features.copy()
```

```
def adjusted_r_square(r,n,p):
  return 1-(1-r)*(n-1)/(n-p-1)
```

Sử dụng hệ số R^2 có hiệu chỉnh có công thức là:

$$r = 1 - (1 - R^2)\frac{n-1}{n-p-1}$$

```
print('Forward stepwise subset selection')
print('Number of features |', 'Features |', 'RSS','|R^2 coefficient')
display([(i,features_list[i], RSS_list[i],adjusted_r_square(R_squared_list[i],df.shape[0],i)) for i in range(1,
```

```
Forward stepwise subset selection
Number of features | Features | RSS |R^2 coefficient
[(1, [3], 23.002033242783682, 0.4900196878616795),
 (2, [3, 1], 19.01410682028911, 0.5536385324260749),
 (3, [3, 1, 4], 17.039434517883574, 0.5749941734425128),
 (4, [3, 1, 4, 0], 16.523450642393016, 0.560388365988296),
 (5, [3, 1, 4, 0, 2], 16.03179517635035, 0.5430025163620834)]
```

Từ đây, ta sẽ chọn 3 ẩn là 1, 3, 4 vì có hệ số R^2 hiệu chỉnh cao nhất.

```
#Construct Z, Y
Z=np.concatenate(((np.ones((df.shape[0],1)),df.iloc[:,1:2],df.iloc[:,3:4],df.iloc[:,4:5])),axis=1)
Y=df.iloc[:,5].values
```

```
a=np.linalg.inv(np.matmul(Z.T,Z))
b=np.matmul(Z.T,Y)
beta_hat=np.matmul(np.matmul(a,Z.T),Y)
beta_hat
```

```
array([-64.43215359,  -0.33647019,   0.11754121,  33.59708406])
```

Từ đây, phương trình hồi quy tuyến tính từ bộ tập con các biến phù hợp là: $ln(Y) = -64.432 - 0.336z_1 + 0.1175z_3 + 33.597z_4$

Ta có dự đoán $\hat{y}$ cần tìm sẽ là

```
y_hat=np.matmul(Z,beta_hat)
y_hat
```

```
array([6.41051131, 4.89912835, 4.05968707, 3.38774539, 3.22024579,
       4.05968707, 4.73162875, 2.59104653, 1.91910485, 4.94187077,
       3.43048781, 1.91910485, 3.85280976, 3.18086808, 5.86766315,
       2.3414268 , 5.53169231, 4.69225104, 4.89912835, 4.05968707])
```

b) Vẽ sai số từ model đã fit ở phần a để kiểm tra giả định về tính chuẩn.

```
residuals=Y-y_hat
residuals
```

```
array([-1.79539079,  0.04963154,  0.50466112,  1.44056835,  0.54095432,
       -1.28709835,  0.50481321, -0.28846144, -0.82049256,  1.0139666 ,
```

```
       0.37617468, -1.22595767,  0.47792358,  1.17584075, -0.79248934,
      -1.24281451, -0.1564139 , -0.40179159,  0.85026464,  1.07611137])
```

```
1 import pylab
2 import statsmodels.api as sm
3 sm.qqplot(residuals,line='r')
4 plt.show()
```

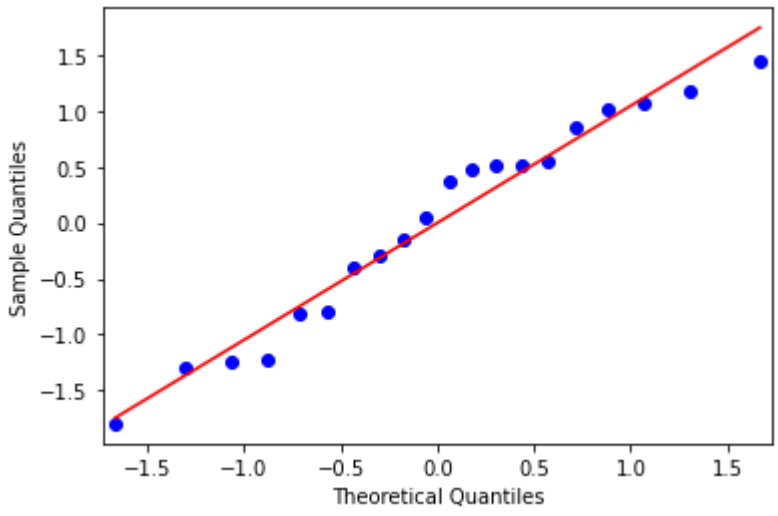

Theo đồ thị q-q plot thì ta thấy sai số của model trên sẽ tuân theo phân phối chuẩn.

✓ 0s completed at 4:47 PM